

采用 UPGMA 方法对距离矩阵构建进化树-实验报告

1. 实验问题：下表数据为 5 条序列的距离矩阵，采用 UPGMA 方法对该距离矩阵构建进化树，要求画每个分支时候需要更新距离矩阵并列出现更新距离的公式。

	A	B	C	D	E
A					
B	22				
C	39	41			
D	39	41	18		
E	41	43	20	10	

2. 相关方法介绍：

利用生物大分子数据重建系统进化树，目前最常用总体上可以分成 4 种方法：距离法（UPGMA, NJ）、最大简约法、最大似然法和贝叶斯法。距离法-非加权分组平均 (UPGMA) 是一种基于距离的聚类方法，常用于构建有根系统发育树。核心思想是通过逐步合并最接近的序列或序列组，从而生成整体的树形结构。具体方法为：

- 1) 输入：需要序列之间的距离矩阵，其中矩阵的每个元素表示两两序列间的进化距
- 2) 寻找最近的两个聚类：在距离矩阵中找到最近的两个聚类节点 (i 与 j)
- 3) 合并聚类：将找到最近的节点 i 和 j 合并成一个节点。计算新节点 U 到其他节点的距离。 $d(U, k) = [d(i, k) + d(j, k)] / 2$
- 4) 更新距离矩阵
- 5) 重复步骤 2-4：直到所有聚类合并为一个树结构。

3. 更新距离矩阵和更新距离公式

在输入矩阵的基础上，找到最近的两个聚类，在这个矩阵中，D、E 之间的距离是最小 (10)。有：((D:5, E:5),)

根据公式更新距离矩阵，相关公式如下：

$$DE \rightarrow A = ((D \rightarrow A) + (E \rightarrow A)) / 2 = (39 + 41) / 2 = 40$$

$$DE \rightarrow B = ((D \rightarrow B) + (E \rightarrow B)) / 2 = (41 + 43) / 2 = 42$$

$$DE \rightarrow C = ((D \rightarrow C) + (E \rightarrow C)) / 2 = (18 + 20) / 2 = 19$$

其他照抄，得到最新的距离矩阵：

	DE	A	B
A	40		
B	42	22	
C	19	39	41

在最新距离矩阵里再找最近距离对，DE 和 C 之间的距离最小 (19)。有：

((D:5, E:5) :9.5, C: 9.5),)

根据公式更新距离矩阵，相关公式如下：

$$DEC \rightarrow A = ((DE \rightarrow A) + (C \rightarrow A)) / 2 = (40 + 39) / 2 = 39.5$$

$$DEC \rightarrow B = ((DE \rightarrow B) + (C \rightarrow B)) / 2 = (42 + 41) / 2 = 41.5$$

其他照抄，得到最新的距离矩阵：

	DEC	A
A	39.5	
B	41.5	22

在最新距离矩阵里再找最近距离对，A 和 B 之间的距离最小（22）。有


((D:5, E:5):9.5, C: 9.5), (A:11, B:11))

$DEC \rightarrow AB = ((DEC \rightarrow A) + (DEC \rightarrow B))/2 = (39.5 + 41.5)/2 = 40.5$

$40.5/2 = 20.25$

最终有：((D:5, E:5):9.5, C: 9.5): 20.25, (A:11, B:11): 20.25)



尝试用 R 语言可视化系统发育树如下，这个系统发育树和 PPT 上面的算法是吻合的。



在使用 R 直接计算的时候，由于计算方法与手工算的会有一些差异，得到 10.83 和 9.33 这两个数字。这使我感到疑惑。理解过后，关键的问题在于这个 DE 作为整体和 C 的距离是怎么计算的。下面这个图的意思按照我的算法理解，这个 20.25 是指从根路径出发到两边距离的尽头的距离。之前的“9.5”，“11”所指也是相同意思。那么如果按照我的方法，手工计算应该是 10.75 和 9.25 这两个数字，也就是说，最终得到的式子是类似的 ((D:5, E:5):4.5, C: 9.5): 10.75, (A:11, B:11): 9.25)，如下右图所示。

UPGMA系统发育树 - 显示分支长度

UPGMA系统发育树 - 显示分支长度




查阅相关资料（B 站视频）如下，有相关视频是支持第二种计算方法，两种计算方法得到的聚类结果是一样的，但是具体数值是不同的：

【【实验】系统发育树，分子系统发育分析，MEGA 软件分子构建系统发育树，Fitch-Margoliash 法，UPGMA 法】

https://www.bilibili.com/video/BV1uM4y1K7zm/?p=4&share_source=copy_web&vd_source

[e=a93608f827604abdba546fb994f1e439](https://a93608f827604abdba546fb994f1e439)

类似此类方法实现得到可视化结果如下：



4. 主要核心相关代码如下：

```
library(ape)
library(ggtree)
library(ggplot2)

# 从距离矩阵直接构建 UPGMA 树
# 创建原始距离矩阵
distance_matrix <- matrix(c(
  0, 22, 39, 39, 41,
  22, 0, 41, 41, 43,
  39, 41, 0, 18, 20,
  39, 41, 18, 0, 10,
  41, 43, 20, 10, 0
), nrow = 5, byrow = TRUE)

# 设置序列名称
rownames(distance_matrix) <- c("A", "B", "C", "D", "E")
colnames(distance_matrix) <- c("A", "B", "C", "D", "E")

# 转换为距离对象
dist_obj <- as.dist(distance_matrix)

# 使用 UPGMA 方法构建进化树
upgma_tree <- hclust(dist_obj, method = "average")

# 转换为 phylo 对象（系统发育树格式）
phylo_tree <- as.phylo(upgma_tree)

# 绘制系统发育树
```

```

par(mfrow = c(2, 2), mar = c(4, 4, 3, 2))

# ===== 使用 ggplot2 + ggtree 绘制系统发育树 =====

# 基础树形图
p1 <- ggtree(phylo_tree, size = 1.2) +
  geom_tiplab(size = 5, fontface = "bold") +
  ggtitle("UPGMA 系统发育树 - ggplot2 样式") +
  theme_tree2() +
  theme(plot.title = element_text(hjust = 0.5, size = 16, face = "bold"))

# 显示分支长度的树（核心功能）
p2 <- ggtree(phylo_tree, size = 1.2) +
  geom_tiplab(size = 5, fontface = "bold", offset = 0.5) +
  geom_label(aes(x = branch, label = round(branch.length, 2)),
    fill = "lightblue", size = 3.5, label.padding = unit(0.2,
"lines")) +
  ggtitle("UPGMA 系统发育树 - 显示分支长度") +
  theme_tree2() +
  theme(plot.title = element_text(hjust = 0.5, size = 16, face = "bold"))
+
  xlim(0, 45)

# 带节点标签的树
p3 <- ggtree(phylo_tree, size = 1.2) +
  geom_tiplab(size = 5, fontface = "bold", offset = 0.5) +
  geom_label(aes(x = branch, label = round(branch.length, 2)),
    fill = "lightblue", size = 3) +
  geom_nodelab(aes(label = node), size = 3, color = "red",
    nudge_x = -1, nudge_y = 0.3) +
  ggtitle("UPGMA 系统发育树 - 带节点编号") +
  theme_tree2() +
  theme(plot.title = element_text(hjust = 0.5, size = 16, face = "bold"))
+
  xlim(0, 45)

# 圆形布局
p4 <- ggtree(phylo_tree, layout = "circular", size = 1.2) +
  geom_tiplab(size = 4, fontface = "bold", offset = 0.5) +
  geom_label(aes(x = branch, label = round(branch.length, 2)),
    fill = "lightgreen", size = 3) +
  ggtitle("UPGMA 系统发育树 - 圆形布局") +
  theme(plot.title = element_text(hjust = 0.5, size = 16, face = "bold"))

# 扇形布局
p5 <- ggtree(phylo_tree, layout = "fan", size = 1.2, open.angle = 180) +
  geom_tiplab(size = 4, fontface = "bold") +
  geom_label(aes(x = branch, label = round(branch.length, 2)),
    fill = "lightyellow", size = 3) +
  ggtitle("UPGMA 系统发育树 - 扇形布局") +
  theme(plot.title = element_text(hjust = 0.5, size = 16, face = "bold"))

```

```
# 显示所有图形  
print(p1)  
print(p2)  
print(p3)  
print(p4)  
print(p5)
```