

 目录索引（第 1 页 - 用彩色纸打印）

使用说明：用彩色标签标记每个部分

 Part 1: 高频简答题答案.....	P2-P15
└─ 题 1: HGP 与生信关系	P2
└─ 题 2: BLAST 原理与应用	P3
└─ 题 3: 生物数据类型及关系	P4
└─ 题 4: 数据库分类+实例	P5-P6
└─ 题 5: GO 数据库全解	P7-P8
└─ 题 6: 基因表达分析	P9-P10
└─ 题 7: 蛋白质功能与分析	P11
└─ 题 8: 系统发生分析	P12
└─ 题 9: 点阵图绘制	P13
└─ 题 10: 富集分析解读	P14-P15
 Part 2: 图表解读万能模板.....	P16-P20
└─ BLAST 结果解读	P16
└─ 火山图/热图/MA 图	P17
└─ GO/KEGG 富集图	P18
└─ 系统发生树	P19
└─ 点阵图解读	P20
 Part 3: 速查表（关键时刻救命）	P21-P24
└─ 数据库分类速查表	P21
└─ 工具与参数速查表	P22
└─ 数值判断标准	P23
└─ 关键概念对比	P24
 Part 4: 论述题万能模板.....	P25-P26
└─ 研究设计四段式模板	P25-P26
 Part 5: 附加题模板.....	P27
 Part 6: 流程图（手绘版）	P28-P30

▣ PART 1: 高频简答题答案 (可直接抄)

【题 1】人类基因组计划的成果与生信关系 (10 分)

📖 考场速写版 (控制在 1 页内)

一、HGP 主要成果——四张图谱 (5 分)

1. 遗传图谱 (Genetic Map)

- 定义: 基于遗传连锁分析, 通过遗传标记 (SNP、微卫星) 确定基因相对位置
- 单位: 厘摩 (cM), 反映重组频率
- 作用: 疾病基因定位、家系研究

2. 物理图谱 (Physical Map)

- 定义: 以实际物理距离 (碱基对 bp) 为单位构建的连续框架
- 标记: STS (序列标签位点)、限制性酶切位点
- 作用: 为测序提供"骨架", 分辨率高于遗传图谱

3. 基因图谱 (Gene Map)

- 定义: 标注基因位置、结构 (外显子、内含子) 和功能
- 方法: 通过 EST (表达序列标签) 或 cDNA 文库
- 作用: 聚焦功能区域, 揭示基因表达信息

4. 序列图谱 (Sequence Map)

- 定义: 完整的 30 亿碱基对序列, 最高分辨率
- 成就: 2003 年完成, 准确率 99.99%
- 作用: 基因组分析的终极目标

二、HGP 与生信的互相促进 (5 分)

(1) HGP 推动生信发展 (2.5 分):

- 海量数据催生需求: GB 级数据倒逼数据库和算法开发
- 算法工具快速发展: BLAST 等序列分析工具应运而生
- 学科独立成型: 生信从边缘学科发展为独立学科

(2) 生信支撑 HGP 完成 (2.5 分):

- 序列组装: 算法将短片段拼接成完整基因组
 - 数据管理: GenBank 等数据库存储海量信息
 - 效率提升: 计算方法使原需数十年工作在 15 年内完成
-

【题 2】BLAST 原理与应用 (10 分)

📖 考场速写版

一、BLAST 基本原理 (5 分)

核心思想: 局部序列比对, 采用启发式算法快速搜索


三步工作流程:

Step 1: 种子搜索

- 将查询序列分解成固定长度"字" (word)
 - 核苷酸: $W=11$
 - 氨基酸: $W=3$
- 在数据库中快速查找完全匹配或高度相似的位置
- 当匹配得分 $\geq$ 阈值 T 时, 确定为"种子"

Step 2: 延伸比对

- 从种子位置向两端延伸
- 用替换记分矩阵计算得分
- 直到得分下降到阈值以下停止
- 形成高分片段对（HSP）



- 查找完全匹配或者高出匹配阈值的短小序列片段对；
- 将它们延伸得到较长的相似性匹配；
- 用替换记分矩阵计算得分，直到达到最大可能得分。

•

一、BLAST的基本原理

BLAST (Basic Local Alignment Search Tool, 基本局部比对搜索工具)

核心思想：局部序列比对，寻找查询序列与数据库序列之间的高度相似区段

工作原理：

1. 种子搜索 (Seeding)
 - 将查询序列分解成固定长度的“字” (word, 通常为3个氨基酸或11个核苷酸)
 - 在数据库中快速查找与这些“字”完全匹配或高度相似的位置
 - 这些匹配位置称为“种子”
2. 延伸 (Extension)
 - 从种子位置向两端延伸比对
 - 计算比对得分，当得分下降到一定阈值时停止延伸
 - 形成高分片段对 (HSP, High-scoring Segment Pair)
3. 评估显著性
 - 使用统计学方法计算E值 (Expected value)
 - E值表示在随机情况下获得相同或更高分的期望次数
 - E值越小，匹配越显著

4. 输出结果
 - 按得分或E值排序输出显著的局部比对结果

算法优势：

- 采用启发式算法，牺牲少量灵敏度换取速度
- 比穷尽比对快数百倍，同时保持较高准确性

•

二、BLAST的主要功能

1. 序列相似性搜索

- 在大型数据库中快速查找与查询序列相似的序列
- 推断未知序列的可能功能

2. 同源序列鉴定

- 发现不同物种间的同源基因/蛋白
- 用于进化分析和比较基因组学研究

3. 功能注释

- 通过相似性推测新基因/蛋白的功能
- 识别保守结构域和功能位点

4. 物种鉴定

- 通过序列比对确定生物物种归属
- 用于分类学研究

三、常用BLAST类型

- BLASTn: 核苷酸序列 vs 核苷酸数据库
- BLASTp: 蛋白质序列 vs 蛋白质数据库
- BLASTx: 核苷酸序列 (翻译后) vs 蛋白质数据库
- tBLASTn: 蛋白质序列 vs 核苷酸数据库 (翻译后)
- tBLASTx: 核苷酸序列 (翻译后) vs 核苷酸数据库 (翻译后)

四、关键参数

- E值 (E-value): 衡量匹配显著性，通常取 10^{-5} 或 10^{-10} 作为阈值
- 覆盖度 (Coverage): 比对区域占查询序列的百分比
- 一致性 (Identity): 匹配碱基/氨基酸的百分比

答题要点：强调BLAST采用“种子-延伸”的启发式策略实现快速局部比对，主要用于序列相似性搜索和功能注释。记住关键词：局部比对、种子搜索、E值统计评估。

Step 3: 统计评估

- 计算 E 值 (Expected value)
- E 值=在随机情况下期望获得该得分的匹配数
- E 值越小，匹配越显著

算法优势：比穷尽比对快数百倍，同时保持高准确性

二、主要功能（2分）

- 序列相似性搜索（在大型数据库快速查找）
- 功能注释（通过相似性推测未知序列功能）
- 同源序列鉴定（跨物种进化分析）
- 物种鉴定（16S rRNA/COI 序列）

三、常用类型（1分）

- BLASTn: 核苷酸 vs 核苷酸

- BLASTp: 蛋白质 vs 蛋白质
- BLASTx: 核苷酸 (翻译) vs 蛋白质
- tBLASTn: 蛋白质 vs 核苷酸 (翻译)
- tBLASTx: 核苷酸 (翻译) vs 核苷酸 (翻译)

四、关键参数 (2 分)

- E 值: $<10^{-5}$ 为显著, $<10^{-50}$ 极显著
- Identity: 相同碱基/氨基酸的百分比
- Coverage: 比对区域占查询序列的百分比

【题 3】生物信息学数据类型及关系 (10 分)

考场速写版

一、主要数据类型 (4 分)

按内容分类:

1. 序列数据: DNA/RNA 序列、蛋白质序列
2. 结构数据: 蛋白质三维结构、RNA 二级结构
3. 数值数据: 基因表达量、蛋白质丰度、代谢物浓度
4. 注释数据: 功能注释、通路信息、文献数据

按组学层次:

- 基因组、转录组、蛋白质组、代谢组、表观基因组

二、数据间关系 (6 分)

(1) 纵向关系——中心法则 (3 分)

DNA (基因组) → 转录 → RNA (转录组) → 翻译 → 蛋白质 (蛋白质组) → 催化 → 代谢物 (代谢组)

- 信息从基因型流向表型
- 遗传信息单向流动
- 构成生命活动基础

(2) 横向关系——调控网络 (2 分)

- 表观调控: DNA 甲基化、组蛋白修饰影响基因表达
- 非编码 RNA 调控: miRNA 调控 mRNA 翻译
- 反馈调控: 代谢物、转录因子反馈调控基因表达

(3) 整合关系 (1 分)

- 单一数据提供局部信息
- 多组学整合实现系统理解
- 从序列→结构→数值→注释形成完整知识链

【题 4】数据库分类+实例 (10-12 分)

考场速写版

一、按总分级分类 (3 分)

1. 一级数据库 (初级/Primary)

- 特点: 存储原始实验数据, 数据量大、冗余高
- 代表: GenBank、PIR、Genome Database、EMBL、DDBJ

2. 二级数据库 (高级/Secondary)

- 特点: 对一级数据库整理、分析、注释, 质量高、冗余低
- 代表: KEGG、CATH、PubMed、Swiss-Prot、Pfam

二、按功能和数据类型分类 (2 分)

1. 核酸序列数据库

- 国际核苷酸序列数据库：NCBI (GenBank)、EMBL、DDBJ
- 三者数据每日同步共享

2. 蛋白质序列及结构数据库

- 序列：PIR、Swiss-Prot、TrEMBL (合并为 UniProt)
- 结构：PDB (Protein Data Bank)

3. 综合或专用数据库

- 综合：KEGG、Ensembl、NCBI
- 专用：miRBase (微小 RNA)、OMIM (遗传疾病)、dbSNP、STRING

三、实例：KEGG 数据库 (5-7 分)

三、数据库实例详解：KEGG 数据库

1. 数据库目的

KEGG (Kyoto Encyclopedia of Genes and Genomes) 是一个系统生物学数据库，主要目的包括：

- 整合基因组、通路和疾病信息，从系统层面理解生物功能
- 建立基因型与表型的联系，连接基因组信息和高级功能
- 支持代谢工程和药物开发，提供生物学通路的系统知识
- 促进比较基因组学研究，跨物种分析代谢和信号通路

(1) 目的与功能 (1 分)

- 整合基因组-通路-疾病信息
- 从系统层面理解生物功能
- 支持代谢工程和药物开发

(2) 存储数据 (2 分)

- KEGG PATHWAY：代谢、信号转导、疾病通路图谱
- KEGG GENES：各物种基因目录与功能注释
- KEGG COMPOUND：代谢物、药物化学结构
- KEGG ENZYME：酶的分类和功能
- KEGG DISEASE：疾病相关基因和通路
- KEGG DRUG：药物靶点信息
- KEGG GENOME：完整基因组信息

(3) 可进行的分析 (2-4 分)

① 通路富集分析

- 判断基因集在哪些通路显著富集
- 差异表达基因功能解读的核心方法
- 输出 p 值、Rich Factor、基因数量

② 功能注释

- 查询基因参与的代谢通路
- 确定基因生物学功能
- 识别基因间功能关联

③ 通路可视化

- 将表达数据映射到通路图
- 观察通路激活/抑制状态
- 红色=上调，绿色=下调

④ 比较基因组学分析

- 跨物种通路比较
- 识别保守和特异性通路
- 研究通路进化


⑤ 疾病与药物研究

- 识别疾病异常通路
- 寻找药物作用靶点
- 药物重定位

【题 5】GO 数据库全解（12 分）


📖 考场速写版

一、GO 的功能（2 分）



GO 结点和关系

每一个节点都是基因或蛋白的一种描述, 并包括注释到该节点的基因, 节点之间保持严格的关系, 即“is a”或“part of”。



GO term之间关系表述

is a 子节点所描述的功能、细胞组分或

生物过程从始至终都是属于父节点的

part of 属于父节点的一部分

regulates


negatively regulates 负向调节

positively regulates 正向调节

箭头代表关系的方向

虚线表示推断的关系

实线表示注释的关系



1. 标准化功能描述: 统一基因功能词汇, 避免混乱
2. 跨物种比较: 相同术语体系, 直接比较功能保守性
3. 计算机可读: 结构化组织, 支持高通量自动分析
4. 功能预测: 为新基因提供注释框架

二、GO 的构成 (4 分)

(1) 三大本体 (Ontology)

- 生物学过程 (BP): 基因参与的生物学目标
 - 例: 细胞周期、DNA 修复、免疫应答
- 分子功能 (MF): 分子水平的活动/催化能力
 - 例: ATP 酶活性、DNA 结合、激酶活性
- 细胞组分 (CC): 亚细胞定位或复合物
 - 例: 细胞核、线粒体、核糖体

(2) 层级结构——有向无环图 (DAG)

- 一个子节点可有多父节点 (多重继承)
- 从具体 (叶节点) 到抽象 (根节点)
- 无环路径

(3) 术语间关系

- is-a: "是一个" (子类与父类)
 - 例: "葡萄糖代谢" is-a "碳水化合物代谢"
- part-of: "部分属于"
 - 例: "有丝分裂" part-of "细胞周期"
- regulates: 调控关系
 - positively_regulates (正调控)
 - negatively_regulates (负调控)

三、基因注释原理 (3 分)

(1) 真实路径规则 (True Path Rule)

- 基因被注释到某节点, 自动继承所有祖先节点
- 注释沿 DAG 向上传递
- 确保逻辑一致性

(2) 证据代码系统

实验证据 (最可靠):

- IDA (直接检测)、IMP (突变表型)
- IGI (遗传相互作用)、IPI (物理相互作用)

计算分析证据:

- ISS (序列相似性)、ISO (同源推测)

电子注释 (可靠性最低):

- IEA (自动注释), 需人工验证

(3) 注释传递机制

- 同源基因间转移功能注释
- 前提: 序列高度相似 (>70%) 且功能保守
- 标记为 ISS/ISO

四、基因功能预测原理 (3 分)

1. 基于序列相似性

- BLAST 搜索→找高相似序列→转移功能注释
- 可靠性取决于 E 值、Identity、Coverage

2. 基于结构域识别

- InterPro/Pfam 扫描保守结构域
- 根据结构域功能预测整体功能

- 例：检测到"激酶结构域"→预测为激酶

3. 基于表达模式

- 共表达基因可能参与相同过程
- 功能罪责联 (guilt by association)

4. 基于蛋白质相互作用

- PPI 网络分析
- 从已知蛋白功能推测未知蛋白

5. 整合策略

- 综合多种证据
 - 机器学习模型
 - 输出预测可信度
-

【题 6】基因表达分析（12 分）

考场速写版

一、原理（2 分）

通过检测 mRNA 丰度反映基因表达水平，比较不同条件下表达差异，揭示生物学过程。主流技术：RNA-seq（高通量测序）。

二、分析流程（5 分）

Step 1: 实验设计与测序

- 确定对照组 vs 处理组，设置生物学重复 (≥ 3)
- RNA 提取→质控→文库构建→测序 (Illumina)
- 产生原始数据 (FASTQ 文件)

Step 2: 数据预处理

- 质量控制 (FastQC): 评估测序质量
- 数据过滤: 去除低质量 reads、修剪接头

Step 3: 比对与定量

- 参考基因组比对 (HISAT2/STAR) →生成 BAM 文件
- 表达量定量 (HTSeq/featureCounts) →表达矩阵

Step 4: 差异表达分析

- 数据标准化 (FPKM/TPM/CPM)
- 统计检验 (DESeq2/edgeR)
- 筛选标准: $|\log_2FC| \geq 1$, $FDR < 0.05$
- 可视化: 火山图、热图、MA 图

Step 5: 功能解读

- GO 富集分析: 识别显著富集的生物学过程
- KEGG 通路富集: 找关键通路
- GSEA: 基因集富集分析

三、应用场景（2 分）

- 疾病机制研究 (肿瘤 vs 正常)
- 药物作用机制 (用药前后)
- 发育过程研究 (不同发育阶段)
- 个性化医疗 (患者分型)

四、实例：肺癌 vs 正常（3 分）

实验设计: 10 例肺癌组织 vs 配对正常组织, RNA-seq

结果:

- 鉴定 3,370 个差异表达基因
 - 上调: 1,523 个 (如 MKI67、CCNB1、TOP2A)
 - 下调: 1,847 个 (如 SFTPC、AGER)

功能富集:

- 上调基因富集于: 细胞周期 ($p < 10^{-20}$)、DNA 复制、有丝分裂
- 提示肿瘤细胞增殖失控

意义:

- 识别潜在治疗靶点
 - 为精准医疗提供分子基础
-

【题 7】蛋白质功能与分析 (12 分)

 考场速写版

一、蛋白质行使功能的途径 (3 分)

1. 酶催化: 催化代谢反应, 突变导致酶活性丧失
 - 例: 苯丙酮尿症 (苯丙氨酸羟化酶缺陷)
2. 信号转导: 传递细胞信号, 异常激活致病
 - 例: Ras 突变导致癌症 (持续激活)
3. 结构支撑: 维持细胞/组织结构
 - 例: 胶原蛋白突变致成骨不全症
4. 转运功能: 物质跨膜转运
 - 例: CFTR 蛋白缺陷致囊性纤维化
5. 免疫识别: 抗原识别与免疫应答
 - 异常引发自身免疫病
6. 蛋白质相互作用: 形成复合物执行功能
 - 网络失调致病

二、生信对蛋白质的分析 (5 分)

1. 序列分析

- BLAST 同源搜索, 推测功能
- 保守结构域识别 (Pfam、InterPro)
- 信号肽、跨膜区预测

2. 结构预测与分析

- 二级结构预测 (α 螺旋、 β 折叠)
- 三维结构建模 (同源建模、从头预测)
- 结构比对与分类 (CATH、SCOP)

3. 功能注释

- GO 功能注释
- 酶功能分类 (EC 编号)
- 活性位点预测

4. 蛋白质相互作用 (PPI)

- 相互作用网络构建 (STRING)
- Hub 蛋白识别

5. 翻译后修饰预测

- 磷酸化、糖基化、泛素化位点

6. 表达与定位

- 组织特异性表达
- 亚细胞定位预测

三、AlphaFold 的影响（4 分）

革命性突破：AlphaFold2 实现原子级精度蛋白质结构预测，准确度接近实验测定。

主要影响：

1. 结构生物学民主化（2 分）

- 降低门槛：无需昂贵实验，几分钟预测结构
- 覆盖度暴增：已预测 2 亿+蛋白结构
- 孤儿蛋白解析：无法结晶蛋白获得结构

2. 加速功能注释（1 分）

- 通过结构推测功能（结构保守性高于序列）
- 识别活性位点、配体结合口袋

3. 推动药物设计（1 分）

- 为药物靶点提供高质量结构
- 基于结构的药物设计（SBDD）
- 抗体优化设计

4. 局限性

- 对多结构域、柔性区域预测仍有挑战
- 无法预测动态构象变化

【题 8】系统发生分析（12 分）



系统发生学

- 系统发生（**phylogeny**）——是指生物形成或进化的历史。
- 系统发生学(**phylogenetics**)——研究物种之间的进化关系。
 - 在分子水平，进化是突变和选择的结果；分子进化是研究生命之树各个分支中基因（蛋白）的变化的理论。
- 系统发生树（**phylogenetic tree, Evolutionary Tree**）——系统发生的表示形式，树的形式描述物种之间进化关系，所谓树是一种图形。



分子系统发生分析的目标

➤ 系统发生学可以回答这样的问题：

1. 我最喜欢的基因是不是受到了选择压力？
2. 灭绝的quagga更像斑马还是马？
3. 达尔文说人类最接近黑猩猩和大猩猩？
4. 鲸鱼、海豚和鼠海豚与牛有多大关系？
5. HIV-1病毒起源于何处及何时？
6. 地球上生命的历史是什么？



系统发生分析和多重序列比对


- 分子系统发生分析的目的是探讨物种之间的进化关系，其分析的对象往往是一组同源的序列。这些序列取自于不同生物基因组的共同位点。
- 序列比对是进行同源分析的一种基本手段，是进行系统发生分析的基础，一般采用基于两两比对渐进的多重序列比对方法，如ClustalW程序。通过序列的比对，可以分析序列之间的差异，计算序列之间的距离。
- 获得两条序列的p距离：比对好以后去掉空位列，不相同的列数除以总的列。



主要内容

1. 分类单元（Operational Taxonomic Units, OTUs）：需要重建（reconstruct）进化关系的物种或者序列。
2. 分支（branch）或者边（edge）：表示物种间的进化关系。
3. 外部节点（external node）或叶节点（leaves）：没有后代的物种（没有分化出新物种）或者序列。
4. 内部节点（internal node）：假设的进化过程中的祖先状态。
5. 二叉树：一个内部节点只有2个直接的后代。

人和黑猩猩的共同祖先



人和黑猩猩的共同祖先




1


生物信息学
BIOINFORMATICS



进化分支图，进化树



- 进化分支图：只有分支信息，无支长信息。



- 进化树：有分支和支长信息，也即拓扑结构和枝长决定了一棵树。

1

生物信息学
BIOINFORMATICS



密码子不同位置有不同的突变接受速率

- 在蛋白质编码序列里影响突变接受速率的另一个因素是突变对氨基酸序列的影响，即潜在的对蛋白质功能的影响。
 1. 同义突变（synonymous mutations）：不改变编码氨基酸的核苷酸变异。
 2. 非同义突变（nonsynonymous）：改变编码氨基酸的核苷酸变异。
- 是否接受非同义突变将依赖于当时施加在物种的进化压力。
 1. 遭受正选择的序列会看到更多的非同义突变。
 2. 遭受负选择的序列同义突变更多。



构造系统发育树的主要方法

- 基于距离的构建方法。
 1. Fitch-Margoliash法
 2. 邻接法（Neighbor Joining Method）
 3. 非加权组平均法 UPGMA
 4. 最小进化方法
- 基于离散特征的构建方法
 1. 最大简约法
 2. 最大似然法
 3. 进化简约法
 4. 相容性方法

- 分子系统发育分析是理解蛋白质（和核苷酸）序列进化方式和相互关系的基础工具。
- 其中主要供分析的输出方式是系统发育树，其本质是对多序列比对结果（包含进化信息）的一种图形化表示。
- 随着目前DNA和蛋白质序列的快速增长趋势，伴随着系统发育树的可视化冲击，使得系统发育分析变得越来越重要并且得到了较为广泛的应用。
- 在病毒基因组进化，原核基因组比较，蛋白质互作网络进化，代谢网络进化，肿瘤细胞微进化等都有重要的应用。

 考场速写版

一、定义（2分）

通过分析生物分子序列（DNA、RNA、蛋白质）的相似性和差异性，推断物种或基因间的进化关系，构建系统发生树（进化树）。

核心思想：序列相似度反映进化距离——序列越相似，关系越近。

二、常用方法（2分）

1. 距离法

- UPGMA、邻接法（NJ）
- 基于遗传距离矩阵

2. 特征法


- 最大简约法（MP）：最少进化事件
- 最大似然法（ML）：统计学最优
- 贝叶斯法：后验概率最高


三、应用场景（2分）

- 物种分类与鉴定
- 进化关系研究
- 基因家族分析
- 病原体溯源（如 COVID-19）
- 保护生物学

四、系统发生树解读（6分）

基本结构：





解读要点:

1. 拓扑结构 (2 分)

- 分支/枝: 进化路径
 - 枝长: 进化距离/时间
 - 长枝=进化快, 短枝=保守
- 节点: 共同祖先
 - 末端节点: 现存物种
 - 内部节点: 假设祖先
- 姐妹群: 共享最近共同祖先的分支
 - 关系最近

2. 进化关系判读 (2 分)

- 看节点位置, 不看上下排列
- 追溯到共同祖先经过节点越少, 关系越近
- 例: 人类-黑猩猩是姐妹群 (最近)

3. 支持度 (1 分)

- Bootstrap 值 (0-100): 重抽样支持度
 - 90: 高度可靠
 - 70-90: 可靠
 - <50: 不可靠
- 贝叶斯后验概率 (0-1)
 - 0.95: 高度支持

4. 外群 (1 分)

- 确定树根 (Root)
- 提供进化方向参考
- 选择与研究对象关系较远但不太远的物种

【题 9】点阵图绘制 (10-12 分)

 考场速写版 (重要: 必考!)

一、点阵图原理 (2 分)

将两条序列分别作为 X 轴和 Y 轴, 逐位比较, 相同位置标点, 可视化序列相似性。

用途:

- 快速识别相似区域
- 发现重复序列、倒位、插入/缺失

二、绘制方法 (5 分)

例题: 给定两段序列, 绘制点阵图

序列 1 (Query): ATGCGATCGAT

序列 2 (Subject): ATCGATCGATA

Step 1: 建立坐标系

A T C G A T C G A T A ← 序列 2

A

T

G

C
G
A
T
C
G
A
T


↑ 序列 1

Step 2: 逐位比较打点

- 如果序列 1[i] = 序列 2[j], 则在(i,j)打点●
- 否则不标记

Step 3: 完整点阵图

A T C G A T C G A T A



三、结果分析 (3-5 分)

1. 识别最长对角线

- 连续对角线=连续相似区域
- 最长对角线: 位置(2,2)→(8,8)
- 共 7 个连续点

最大相似序列:

序列 1: T C G A T C G (位置 2-8)

序列 2: T C G A T C G (位置 2-8)

答案: TCGATCG (7 个碱基)

2. 其他模式解释

- 多条平行对角线: 序列内部重复
- 断裂对角线: 插入/缺失
- 反向对角线: 反向互补序列

【题 10】富集分析解读 (10 分)

 考场速写版

一、富集分析原理 (2 分)

目的: 在一组基因 (如差异表达基因) 中, 找出显著富集的功能类别或通路

统计原理：超几何分布检验

- 问题：在 N 个基因中随机抽 n 个，其中 k 个属于某功能，是否显著？
- 校正：FDR 多重假设检验校正

二、GO 富集柱状图解读（3 分）


GO Terms	Gene Count	$-\log_{10}(p)$
cell cycle		20.5
DNA replication		15.3
mitotic division		14.2

解读要点：

- 横轴： $-\log_{10}(p\text{-value})$ ，越大越显著
 - $-\log_{10}(0.05) \approx 1.3$ （阈值）
 - $-\log_{10}(10^{-20}) = 20$ （极显著）
- 柱长/颜色：显著性水平
- 数值：富集到该 term 的基因数

生物学解释： "差异基因显著富集于细胞周期相关过程 ($p < 10^{-20}$)，提示肿瘤细胞增殖失控。 "

三、KEGG 富集气泡图解读（5 分）



气泡大小 = 基因数量

气泡颜色 = p 值（红=显著）

解读要点：

1. Rich Factor（2 分）

Rich Factor = (该通路的差异基因数) / (该通路的背景基因总数)

- 值越大，富集程度越高
- 例：0.3 表示该通路 30% 基因都是差异基因

2. 气泡大小（1 分）

- 富集到该通路的基因数量
- 大气泡=更多基因参与

3. 气泡颜色（1 分）

- 红色/深色：p 值小（高度显著）
- 蓝色/浅色：p 值大（不显著）

实例解读（1 分）：

通路：Cell cycle (hsa04110)

Rich Factor: 0.25

基因数: 45

p-value: 1.2×10^{-15}

解释： "细胞周期通路中 25% 的基因出现在差异基因列表中，共 45 个基因富集 ($p = 1.2 \times 10^{-15}$ ，极显著)，提示细胞周期是核心受影响过程。 "

【模板 1】BLAST 结果解读 (10 分)

标准解读框架

典型 BLAST 结果:

Query: 你的序列 (500 bp)

Sequences producing significant alignments:

	Score	E-value
gi 12345 Homo sapiens TP53 gene	872	0.0
gi 23456 Mus musculus Trp53 gene	654	2e-185
gi 34567 Rattus norvegicus Tp53	623	1e-176

解读要点:

1. E 值 (Expected Value) ★★★★★

定义: 在随机情况下, 期望获得相同或更高分数的匹配数

数值标准:

E 值范围	显著性	解释
$E < 10^{-50}$	几乎完全相同	极高可信度
$10^{-20} \sim 10^{-50}$	高度相似	同源关系可靠
$10^{-5} \sim 10^{-20}$	中等相似	可能同源
$10^{-2} \sim 10^{-5}$	低相似性	需谨慎判断
$E > 0.01$	不显著	可能随机匹配

例子解读:

- $E=2e-185 \rightarrow 2 \times 10^{-185}$, 几乎不可能随机出现, 真实同源

2. 序列一致性 (Identity) ★★★★★

定义: 完全匹配的碱基/氨基酸占比对区域的百分比

数值标准:

Identity 解释

>90%	非常高, 可能同物种同基因
70-90%	高相似, 近缘物种直系同源
40-70%	中等, 可能旁系同源或保守结构域
<40%	低相似, 同源存疑 (但蛋白质 40%已可靠)

3. 覆盖度 (Coverage) ★★★★★

定义: 比对区域占查询序列的百分比

Coverage 解释

>80%	几乎全长匹配, 可靠
50-80%	部分匹配, 可能结构域相似
<50%	局部匹配, 仅保守区域相似

综合判断公式:

高质量匹配 = 低 E 值 ($<10^{-20}$) + 高 Identity ($>70\%$) + 高 Coverage ($>80\%$)


标准答题模板:

"该 BLAST 结果显示查询序列与人类 TP53 基因高度匹配 ($E=0.0$, 即 $E<10^{-180}$, 几乎完美匹配; Identity=98%, 仅 10 个碱基不同; Coverage=98%, 几乎全长比对)。综合判断, 查询序列极可能是人类 TP53 基因或其等位基因变体。"

【模板 2】火山图/热图/MA 图解读（10 分）

 火山图 (Volcano Plot)

图形结构：



解读要点：

X 轴: $\log_2(\text{Fold Change})$

- 右侧 (>0): 上调基因
- 左侧 (<0): 下调基因
- $|\log_2\text{FC}| \geq 1$ 表示差异 ≥ 2 倍

Y 轴: $-\log_{10}(\text{p-value})$

- 越往上越显著
- $-\log_{10}(0.05) \approx 1.3$ (显著性阈值线)


点的颜色：

- 红色●：显著上调
- 蓝色●：显著下调
- 灰色○：不显著

标准答题： "火山图显示，共有 XXX 个显著差异表达基因（红色/蓝色点）。最显著的上调基因为 XXX ($\log_2\text{FC}=\text{X.X}$, $p<10^{-\text{XX}}$), 最显著的下调基因为 XXX。大部分基因无显著变化（灰色点聚集在中央）。"

 热图 (Heatmap)

图形结构：



深色=高表达，浅色=低表达

解读要点：


行聚类：功能相似基因聚在一起 列聚类：表达模式相似样本聚在一起 清晰分组：对照与处理完全分开→差异明显 共表达模块：

同时上调/下调的基因簇→同一通路

标准答题： "热图显示对照组与处理组样本完全分离，表明处理效果显著。基因聚类形成 X 个主要模块，其中模块 1 包含 XX 个基因在处理组中显著上调（红色），可能参与 XXX 过程。"

 MA 图

图形结构：



• • •


X 轴 (A): 平均表达量 = $[\log_2(\text{对照}) + \log_2(\text{处理})]/2$ Y 轴 (M): $\log_2\text{FC}$ 分布特征:

- 大部分点在 $y=0$ 附近 (无差异)
- 高表达基因 (右侧) 检测更可靠
- 低表达基因 (左侧) 易受噪音影响

【模板 3】系统发生树解读（10 分）

系统发生树标准解读

基本结构：



0.05 替换/位点

解读框架：

1. 拓扑关系（说清楚谁和谁近）

- 人类与黑猩猩是姐妹群，关系最近
- 人-黑猩猩与大猩猩-猩猩形成更大进化支
- 长臂猿最早分化
- 外群定义树根

2. 支持度 (判断可靠性)

- 人-黑猩猩节点 Bootstrap=98 → 高度可信
- 大猩猩-猩猩节点 Bootstrap=85 → 可靠

3. 进化距离 (看枝长)

- 标尺"0.05 替换/位点"=每 100 个核苷酸有 5 个替换
- 枝长反映进化时间/突变速率

4. 生物学结论

- 人类与黑猩猩约 600-700 万年前分化
- 验证人类在灵长类中的系统位置
- 支持人科的单系性

标准答题模板：

"该系统发生树显示：(1) 拓扑关系：XXX 与 XXX 为姐妹群（关系最近），XXX 最早分化。(2) 支持度：关键节点 Bootstrap 值为 XX，表示可靠/高度可靠。(3) 进化距离：标尺显示 XX 替换/位点，枝长反映进化速率。(4) 生物学意义：验证了 XXX 的系统位置，支持 XXX 假说。"

PART 3: 速查表 (救命用)

【速查表 1】数据库分类速查

数据库名称	分级	类型	主要功能	网址/关键词
GenBank	一级	核酸序列	存储原始序列	NCBI
EMBL	一级	核酸序列	欧洲序列库	EBI
DDBJ	一级	核酸序列	日本序列库	DDBJ
PIR	一级	蛋白序列	蛋白信息资源	PIR
KEGG	二级	综合	通路分析	pathway
GO	二级	功能注释	基因本体论	geneontology
PDB	一级	蛋白结构	3D 结构	rcsb.org
UniProt	二级	蛋白序列	Swiss-Prot+TrEMBL	uniprot
Pfam	二级	蛋白结构域	蛋白家族	pfam
OMIM	二级	疾病	人类遗传病	omim.org
STRING	二级	PPI	蛋白互作	string-db
PubMed	二级	文献	生医文献库	pubmed

【速查表 2】工具与参数速查

分析目的	工具/方法	关键参数/阈值
序列比对	BLAST	$E < 10^{-5}$, Identity > 40%(蛋白)/70%(核酸)
差异表达	DESeq2/edgeR	$ \log_2 FC \geq 1$, FDR < 0.05
GO 富集	clusterProfiler	p < 0.05, 校正后
KEGG 富集	DAVID/Metascape	p < 0.05, Rich Factor
系统发生	MEGA/RAxML	Bootstrap > 70
结构预测	AlphaFold2	pLDDT > 70 (可信)
PPI 网络	STRING	Combined score > 0.4
蛋白结构域	InterPro/Pfam	E < 0.01

【速查表 3】数值判断标准（必背!）

E 值标准	
E 值	显著性
$< 10^{-50}$	几乎完全相同
$10^{-20} \sim 10^{-50}$	高度相似，同源可靠
$10^{-5} \sim 10^{-20}$	中等相似，可能同源
> 0.01	不显著
Identity 标准	
Identity 解释	
$> 90\%$	非常高（同物种）
70-90%	高相似（近缘物种）
40-70%	中等（保守结构域）
$< 40\%$	低相似（核酸存疑，蛋白可靠）
Bootstrap 标准	
Bootstrap 可靠性	

Bootstrap 可靠性

>90 高度可靠

70-90 可靠

<50 不可靠

差异基因筛选标准

$|\log_2\text{FC}| \geq 1$ (差异 ≥ 2 倍)

FDR < 0.05 (校正后 p 值)

p 值显著性

p < 0.05: 显著

p < 0.01: 非常显著

p < 0.001: 极显著

【速查表 4】关键概念对比

相似性 vs 同源性

特征	相似性	同源性
----	-----	-----

性质	定量 (数值)	定性 (是/否)
----	---------	----------

表述	80%相似 ✓	80%同源 X
----	---------	---------

计算	可精确计算	不能计算
----	-------	------

意义	序列相像度	进化关系
----	-------	------

一级 vs 二级数据库

特征	一级数据库	二级数据库
----	-------	-------

数据来源	原始实验	一级数据库加工
------	------	---------

冗余度	高	低
-----	---	---

注释	简单	详细
----	----	----

代表	GenBank, PIR	KEGG, Swiss-Prot
----	--------------	------------------

HGP 四张图谱

图谱	单位	特点
----	----	----

遗传图谱	cM (厘摩)	相对位置, 重组频率
------	---------	------------

物理图谱	bp	物理距离, 分辨率高
------	----	------------

基因图谱	基因位置	功能标注
------	------	------

序列图谱	30 亿 bp	完整序列, 最高分辨率
------	---------	-------------

GO 三种关系

关系	含义	例子
----	----	----

is-a	"是一个"	葡萄糖代谢 is-a 碳水化合物代谢
------	-------	--------------------

part-of	"部分属于"	有丝分裂 part-of 细胞周期
---------	--------	-------------------

regulates	调控	positively/negatively regulates
-----------	----	---------------------------------

📅 PART 4: 论述题万能模板 (600 字版)

【论述题】膀胱癌性别差异研究设计 (30 分)

📄 万能四段式 (直接套用)

一、研究背景与意义

膀胱癌发病率存在显著性别差异，男性发病率是女性的 3-4 倍，但女性患者预后更差，诊断时常处于晚期。尽管临床现象明确，但其分子机制尚不清楚。本研究旨在利用生物信息学方法系统分析膀胱癌的性别特异性分子特征，识别关键差异基因和通路，构建性别特异性预后模型，为精准医疗提供理论依据和临床工具。

二、研究思路与方法

(一) 数据收集与差异表达分析

首先从 TCGA-BLCA 数据库获取膀胱癌患者的转录组数据（约 412 例，包含男性 300 余例、女性 100 余例），同时收集完整的临床信息（性别、年龄、分期、预后等）。对 RNA-seq 数据进行标准化处理后，使用 DESeq2 进行差异表达分析，比较男性与女性膀胱癌患者的基因表达谱差异，筛选标准为 $|\log_2FC| \geq 1$ 且 $FDR < 0.05$ 。重点关注性别特异性表达基因（仅在一性别中显著差异）以及性激素受体相关基因（ESR1、ESR2、AR 等）。对差异表达基因进行 GO 和 KEGG 富集分析，识别性别特异性激活的生物学过程和信号通路，如激素信号通路、免疫应答、细胞增殖等关键通路。

(二) UK Biobank 大队列验证

为确保发现的可靠性，利用 UK Biobank (UKB) 中的膀胱癌队列进行独立验证。UKB 是全球最大的生物医学数据库之一，包含 50 万参与者的基因型、表型和健康记录数据。从 UKB 中筛选膀胱癌患者，提取基因表达或基因型数据，验证 TCGA 中发现的性别差异基因在独立大样本中是否一致。同时结合 UKB 的长期随访数据，分析这些差异基因与患者生存、疾病进展的关联，评估其作为生物标志物的潜力。大队列验证可消除单一数据集的偏倚，提高结果的普适性和临床转化价值。

(三) 机器学习构建性别特异性预后模型

基于 TCGA 数据，筛选与预后显著相关的性别差异基因，采用机器学习方法构建预后预测模型。具体流程如下：首先通过单因素 Cox 回归筛选与总生存期相关的基因 ($p < 0.05$)，然后使用 LASSO 回归进行特征降维，选择最优基因组合。分别为男性和女性患者构建独立的预后风险评分模型，计算每位患者的风险评分 (Risk Score)，并根据评分中位数将患者分为高风险组和低风险组。在训练集中评估模型性能后，使用测试集和 UKB 队列进行外部验证，绘制 Kaplan-Meier 生存曲线和 ROC 曲线（期望 AUC > 0.75），评估模型的预测准确性。进一步结合临床变量（年龄、分期、肿瘤分级）构建联合预测模型，提高临床实用性。

三、实验验证与临床转化

对于生信分析中识别的关键性别差异基因，选择代表性基因在膀胱癌细胞系中进行 qRT-PCR 和 Western blot 验证，确认其在不同性别来源细胞中的表达差异。通过 siRNA 敲低或过表达实验，结合细胞增殖、侵袭迁移等功能实验，探索这些基因在膀胱癌性别差异中的功能作用。如条件允许，可收集临床患者组织样本进行免疫组化验证，评估候选基因的蛋白表达水平与患者性别、预后的关联。

四、预期结果与临床价值

本研究预期将识别出 100-200 个性别差异表达基因，发现性激素信号通路、免疫微环境等关键通路的性别特异性特征，构建出男性和女性各自的预后基因签名模型。研究结果将为膀胱癌的性别化精准医疗提供分子基础，帮助临床医生根据患者性别制定个性化治疗方案，识别高危患者进行密切监测，并为开发性别特异性治疗靶点提供候选分子，具有重要的科学价值和临床转化意义。

字数：约 630 字 用时：25-30 分钟

💡 其他论述题套路

如果题目是："谈谈生物信息学在精准医学中的应用"

套用模板：

1. 背景：精准医学的兴起+生信的作用
2. 方法：
 - 基因组测序与变异分析
 - 多组学数据整合
 - 机器学习建模

3. 实验结合：临床样本验证
4. 价值：个性化治疗、预后预测

📁 PART 5: 附加题模板 (10 分)

【附加题】对生物信息学课程的感想和建议

📄 万能模板 (5 分钟速写)

一、学习收获与进步 (5 分)

通过本学期生物信息学的学习，我在以下几个方面取得了显著进步：

1. 知识体系构建

- 系统掌握了生物信息学的核心概念，包括序列分析、数据库应用、基因表达分析等
- 理解了从基因组到表型的多组学数据整合思路
- 认识到生物信息学在现代生命科学研究中的重要地位

2. 分析工具运用

- 学会使用 BLAST 进行序列比对和功能注释
- 掌握了基因表达差异分析的基本流程 (RNA-seq 分析)
- 了解了 GO/KEGG 富集分析的原理和应用

3. 科研思维培养

- 学会了如何设计生物信息学研究方案
- 理解了生物信息学与实验科学结合的重要性
- 培养了利用公共数据库进行大数据挖掘的意识

4. 自主学习能力

- 通过文献阅读和课后练习，提高了自主学习能力
- 学会了查阅在线资源和使用生信工具

二、建议与展望 (5 分)

对课程的建议：

1. 增加实践环节：建议增加上机实操时间，让学生亲手运行分析流程
2. 案例教学：多引入最新研究案例，展示生信在实际科研中的应用
3. 分层教学：考虑不同专业背景学生的需求，提供基础和进阶两个层次
4. 工具培训：系统讲解常用生信工具的安装和使用

个人展望：

- 希望在今后的科研工作中应用生物信息学方法
- 计划继续学习编程语言 (如 Python、R) 以提高分析能力
- 期待将生信分析与临床/实验研究相结合

感谢：感谢老师们的悉心教导，让我认识到生物信息学在现代医学研究中的巨大潜力。这门课程为我未来的科研道路打下了坚实的基础。

字数：约 400 字 用时：5-8 分钟