

 PART 1: 简答题标准答案（10 选 7，每题 10 分）

【题 1】生物信息学数据对象及关系（10 分）

标准答案框架（控制在 1 页内）：

一、主要数据对象（5 分）

（1）按内容分类（3 分）：

1. 序列数据

- DNA 序列：基因组测序数据（FASTA/FASTQ 格式）
- RNA 序列：转录组数据（mRNA、ncRNA）
- 蛋白质序列：氨基酸序列（UniProt 格式）

2. 结构数据

- 蛋白质三维结构（PDB 数据库）
- RNA 二级/三级结构
- 分子对接数据

3. 数值数据

- 基因表达量（RNA-seq 的 counts/FPKM）
- 蛋白质丰度（质谱数据）
- 代谢物浓度

4. 注释数据

- 功能注释（GO、KEGG）
- 通路信息
- 文献数据（PubMed）


（2）按组学层次分类（2 分）：

- 基因组（Genome）
- 转录组（Transcriptome）
- 蛋白质组（Proteome）
- 代谢组（Metabolome）
- 表观基因组（Epigenome）

二、数据间关系（5 分）

（1）纵向关系——中心法则（3 分）

DNA(基因组) → 转录 → RNA(转录组) → 翻译 → 蛋白质(蛋白质组)



- **信息流动方向**：遗传信息从 DNA→RNA→蛋白质→代谢物，最终决定表型
- **单向流动**：中心法则规定信息传递的主要方向
- **生命基础**：构成生命活动的基本规律

（2）横向关系——调控网络（1.5 分）

- **表观调控**：DNA 甲基化、组蛋白修饰调控基因表达

- **非编码 RNA 调控**: miRNA 调控 mRNA 翻译和稳定性
- **反馈调控**: 代谢物、转录因子反馈调控基因表达

(3) 整合关系——系统生物学 (0.5 分)

- 单一组学数据提供局部信息
 - 多组学整合实现系统理解
 - 从序列→结构→功能→调控形成完整知识链
-

【题 2】NCBI 数据库 (10-12 分)

标准答案框架:

一、NCBI 基本概况 (2 分)

NCBI (National Center for Biotechnology Information, 美国国家生物技术信息中心) 是全球最大的生物信息学数据资源中心, 提供综合的分子生物学数据库和分析工具。

二、存储结构 (3 分)

(1) 核心数据库系统:

1. GenBank - 核心序列数据库

- 存储所有公开的核酸序列
- 与 EMBL、DDBJ 每日同步
- 数据持续增长 (目前超过 2000 亿条碱基)

2. RefSeq - 参考序列数据库

- 经过人工审核的高质量序列
- 非冗余、注释完善
- 包含基因组、转录本、蛋白质序列

3. 专用数据库:

- **PubMed**: 生物医学文献数据库
- **Gene**: 基因特异性信息
- **Protein**: 蛋白质序列和注释
- **dbSNP**: 单核苷酸多态性
- **dbGaP**: 基因型-表型关联
- **GEO**: 基因表达数据
- **SRA**: 测序原始数据

(2) 数据层次结构:

EntrezGenome(完整基因组)



Gene(基因)



Nucleotide(核酸序列)



Protein(蛋白质序列)



Structure(三维结构-链接到 PDB)

三、提供的应用工具 (3 分)

(1) 序列分析工具:

- **BLAST**: 序列相似性搜索
- **ORF Finder**: 开放阅读框查找

- **Primer-BLAST**: 引物设计

(2) 比对和进化工具:

- **COBALT**: 多序列比对
- **Tree Viewer**: 系统发生树可视化

(3) 数据检索工具:

- **Entrez**: 统一检索系统
- **E-utilities**: 编程接口 (API)

(4) 分析平台:

- **Genome Workbench**: 基因组分析平台
- **CDD**: 保守结构域数据库

四、如何利用相关数据 (2-4 分)

(1) 基础查询流程:

Step 1: 选择数据库

- 根据研究目的选择 (Nucleotide/Protein/Gene/PubMed)

Step 2: 使用 Entrez 检索

- 关键词搜索 (基因名、物种、功能)
- 高级搜索 (组合条件)

Step 3: 结果筛选

- 按物种、序列类型、发表时间过滤
- 查看详细注释信息

Step 4: 数据下载

- FASTA 格式 (序列)
- GenBank 格式 (完整注释)
- CSV/XML 格式 (批量数据)

(2) 典型应用场景:

场景 1: 未知基因功能注释

流程:

序列 → BLAST 比对 → 找同源基因 →
查看 Gene 数据库 → 获取功能注释 →
关联 KEGG 通路 → 预测功能

场景 2: 疾病相关基因研究

流程:

PubMed 检索疾病 → 找相关基因 →
Gene 数据库查基因 → 下载序列 →
RefSeq 获取参考序列 → dbSNP 查变异 →
GEO 查表达数据 → 综合分析

场景 3: 比较基因组学

流程:

Genome 数据库下载多物种基因组 →
BLAST 比对找同源基因 →
COBALT 多序列比对 →
Tree Viewer 构建进化树 →
分析保守性和特异性

(3) 编程化利用:

- 使用 E-utilities API 批量下载
- Python 的 Biopython 库调用 NCBI
- R 的 rentrez 包访问数据

【题 3】BLAST 原理+图表解读（已完成）

见前面的详细解读！

【题 4】点阵图绘制（10-12 分）☆☆☆ 必考！

题目：

序列 1 (X 轴)：CGCCTCACATA

序列 2 (Y 轴)：TGTCCTCAGA

标准答案（手绘+说明）：

一、点阵图绘制（6 分）

Step 1: 建立坐标系（1 分）

C G C C T C A C A T A ← 序列 1(X 轴)

T |
G |
T |
C |
C |
C |
T |
C |
A |
G |
A |

↑

序列 2(Y 轴)

Step 2: 逐位比较打点（3 分）

规则：如果序列 1[i] = 序列 2[j]，在坐标(i,j)处标记●

Step 3: 完整点阵图（2 分）

C G C C T C A C A T A

T		.	.	.	.	●	.	.	.	●	.
G		.	●	.	.	.	.	.	.	.	.
T		.	.	.	●	.	.	.	●	.	.
C		●	.	●	●	.	●	.	●	.	.
C		●	.	●	●	.	●	.	●	.	.
C		●	.	●	●	.	●	.	●	.	.
T		.	.	.	●	.	.	.	●	.	.
C		●	.	●	●	.	●	.	●	.	.
A		.	.	.	.	●	.	●	.	●	.
G		.	●	.	.	.	.	.	.	.	.

A | ● . ● . ●

二、识别最大相似片段 (4 分)

(1) 寻找对角线 (2 分)

观察点阵图，寻找连续的对角线（左下→右上方向）

主要对角线：

- 对角线 1：位置(4,4)→(8,8)，长度 4 (C-C-C-T-C)
- 对角线 2：位置(7,9)→(9,11)，长度 3 (A-A)

(2) 确定最大相似片段 (2 分)

最长对角线分析：

位置(1,4)到(6,9)的区域有多个 C 的匹配

仔细观察最长连续对角线：

- 从序列 2 的第 4 个位置 (C) 开始
- 匹配序列 1 的第 1,3,4,6,8 位置的 C

最大连续片段：

实际上最长连续对角线为：

- 位置范围：序列 1 的 3-6 位(CCTC)对应序列 2 的 4-7 位(CCCT)
- 但这不是完全连续的对角线

让我重新分析最长连续对角线：

从图中看，最长的连续对角线是：

- C(1,4) → C(3,5) → C(4,6)这样的断续对角线
- 或者 A(7,9) → A(9,11)

标准答案应该写：

最大相似片段分析：

观察点阵图中的连续对角线，识别出：

1. 最长连续匹配：

序列 1 位置 7-9: ACA

序列 2 位置 9-11: AGA

相似度：2/3 (AA 匹配)

2. 另一显著匹配区域：

序列 1 位置 1-6: CGCCTC

序列 2 位置 4-9: CCCCTC

该区域虽有多 C 匹配，但不完全连续

结论：两序列最大连续相似片段为"CA"（长度 2），

位于序列 1 的第 7-8 位和序列 2 的第 9-10 位。

【题 5】GO 基因注释原理+图表 (10 分)

标准答案框架：

一、GO 基因注释原理 (7 分)

(1) 核心原理——有向无环图 (DAG) 结构 (2 分)

GO 采用 DAG (Directed Acyclic Graph) 组织术语：

- 从具体术语（叶节点）到抽象术语（根节点）
- 一个子节点可有多个父节点（多重继承）
- 保证无循环路径

(2) 真实路径规则 (True Path Rule) (2 分)

基因被注释到某个 GO 术语时：

- 自动继承该术语的所有祖先节点
- 注释沿 DAG 向上传递
- 确保逻辑一致性

示例：

如果基因 X 被注释为“葡萄糖代谢”(GO:0006006)

则自动继承：

- 碳水化合物代谢 ↑
- 有机物代谢 ↑
- 初级代谢过程 ↑
- 代谢过程 ↑
- 生物学过程（根节点）↑

(3) 证据代码系统 (Evidence Codes) (2 分)

实验证据（最可靠）：

- **IDA** (Inferred from Direct Assay)：直接实验检测
- **IMP** (Inferred from Mutant Phenotype)：突变表型推断
- **IGI** (Inferred from Genetic Interaction)：遗传互作推断
- **IPI** (Inferred from Physical Interaction)：物理互作推断

计算分析证据：

- **ISS** (Inferred from Sequence Similarity)：序列相似性推断
- **ISO** (Inferred from Sequence Orthology)：同源序列推断

电子注释（可靠性最低）：

- **IEA** (Inferred from Electronic Annotation)：自动注释，需人工验证

(4) 注释传递机制 (1 分)

- 通过同源基因转移功能注释
- 前提：序列高度相似 (>70% identity) 且功能保守
- 标记为 ISS 或 ISO 证据代码

二、图表解读 (3 分)

[根据具体图表内容解读，通常考 GO 的 DAG 结构图或注释流程图]

典型图表类型：

类型 1：GO DAG 结构图

解读要点：

1. 识别三大本体 (BP/MF/CC)
2. 指出术语间的关系类型 (is-a/part-of/regulates)
3. 说明从叶节点到根节点的层级关系
4. 举例说明多重继承现象

类型 2：GO 注释流程图

解读要点：

1. 说明注释来源 (实验/计算/自动)
2. 指出证据代码

3. 解释注释传递路径
 4. 说明质量控制机制
-

【题 6】GO 数据库功能构成+原理（12 分）

标准答案框架：

一、GO 数据库的基本功能（3 分）

1. 标准化功能描述

- 提供统一的基因功能词汇体系
- 避免不同实验室使用不同术语的混乱

2. 跨物种功能比较

- 相同 GO 术语可用于不同物种
- 直接比较功能保守性

3. 高通量数据分析

- 结构化组织支持计算机自动分析
- 富集分析、功能聚类等应用

4. 功能预测框架

- 为新发现基因提供注释框架
- 基于已知基因推测未知基因功能

二、GO 数据库的构成（4 分）

（1）三大本体（Ontology）（2 分）

1. 生物学过程（Biological Process, BP）

- 定义：基因参与的生物学目标或系列事件
- 例子：细胞周期、DNA 修复、免疫应答、凋亡

2. 分子功能（Molecular Function, MF）

- 定义：分子水平的活动或催化能力
- 例子：ATP 酶活性、DNA 结合、激酶活性、转录因子活性

3. 细胞组分（Cellular Component, CC）

- 定义：亚细胞定位或大分子复合物
- 例子：细胞核、线粒体、核糖体、质膜

（2）层级结构——有向无环图（DAG）（1 分）

- 一个子节点可有多个父节点（多重继承）
- 从具体（叶节点）到抽象（根节点）
- 无环路径保证逻辑一致性

（3）术语间关系（1 分）

is-a 关系："是一个"（子类与父类）

- 例："葡萄糖代谢" is-a "碳水化合物代谢"

part-of 关系："部分属于"

- 例："有丝分裂" part-of "细胞周期"


regulates 关系：调控关系

- positively_regulates（正调控）
- negatively_regulates（负调控）

三、基因功能注释原理（2 分）

（1）注释流程：

基因序列



(2) 注释依据:

- 实验证据 (IDA/IMP/IGI/IPI)
- 序列相似性 (ISS)
- 同源推断 (ISO)
- 自动注释 (IEA)

四、基因功能预测原理 (3 分)

(1) 基于序列相似性预测 (1 分)

流程:

未知基因 → BLAST 搜索 → 高相似已知基因 →
转移 GO 注释 → 预测功能

可靠性取决于:

- E 值 ($<10^{-5}$ 更可靠)
- Identity ($>70\%$ 更可靠)
- Coverage ($>80\%$ 更可靠)

(2) 基于结构域识别预测 (1 分)

流程:

蛋白质序列 → InterPro/Pfam 扫描 →
识别保守结构域 → 根据结构域功能 →
预测整体功能

例子:

- 检测到“激酶结构域” → 预测为激酶
- 检测到“DNA 结合域” → 预测为转录因子

(3) 基于表达模式预测 (0.5 分)

- 共表达基因可能参与相同生物学过程
- 功能罪责联 (Guilt by Association) 原则

(4) 基于蛋白质相互作用预测 (0.5 分)

- PPI 网络分析
- 与已知功能蛋白互作 → 推测未知蛋白功能

【题 7】基因表达分析流程+应用 (12 分)

标准答案框架:

一、基因表达分析原理 (2 分)

通过检测 mRNA 丰度反映基因表达水平, 比较不同条件 (如疾病 vs 正常、处理 vs 对照) 下的表达差异, 揭示生物学过程和疾病机制。

****主流技术: **RNA-seq (高通量测序)**

二、基本流程 (5 分)

Step 1: 实验设计与测序 (1 分)

设计:

- 确定对照组 vs 实验组
- 设置生物学重复 (≥ 3)
- 控制混杂因素

测序:

- RNA 提取与质控
- 文库构建 (去 rRNA/富集 mRNA)
- Illumina 测序
- 产生 FASTQ 文件

Step 2: 数据预处理 (1 分)

质量控制:

- FastQC 评估测序质量
- MultiQC 汇总报告

数据过滤:

- Trimmomatic 去除低质量 reads
- Cutadapt 修剪接头序列

Step 3: 比对与定量 (1 分)

参考基因组比对:

- HISAT2/STAR 比对到参考基因组
- 生成 SAM/BAM 文件

表达量定量:

- HTSeq-count/featureCounts 计数
- 生成表达矩阵 (基因 $\times$ 样本)

Step 4: 差异表达分析 (1.5 分)

数据标准化:

- FPKM/TPM/CPM 标准化
- 消除测序深度差异

统计检验:

- DESeq2 (负二项分布模型)
- edgeR (精确检验)

筛选标准:

- $|\log_2FC| \geq 1$ (差异 ≥ 2 倍)
- $FDR < 0.05$ (校正后 p 值)

可视化:

- 火山图 (Volcano Plot)

- 热图 (Heatmap)

- MA 图

Step 5: 功能解读 (0.5 分)

GO 富集分析:

- 识别显著富集的生物学过程

KEGG 通路富集:

- 找出关键调控通路

GSEA 分析:

- 基因集富集分析

三、应用实例 (5 分)

实例 1: 肺癌分子分型研究 (完整版)

(1) 研究背景 (1 分) 肺癌是全球癌症死亡首因, 不同分子亚型对治疗响应不同, 需要精准分型指导个体化治疗。

(2) 实验设计 (1 分)

- 样本: 肺腺癌组织 100 例 vs 配对正常组织 100 例
- 技术: RNA-seq (Illumina NovaSeq 平台)
- 测序深度: 50M reads/样本

(3) 分析流程 (1.5 分)

FASTQ 数据

↓ FastQC 质控

Trim 后 FASTQ

↓ HISAT2 比对

BAM 文件

↓ featureCounts 定量

表达矩阵

↓ DESeq2 差异分析

差异基因列表

↓ 聚类分析

分子亚型

(4) 主要发现 (1 分)

差异基因识别:

- 鉴定 3,370 个显著差异表达基因
 - 上调: 1,523 个 (如 MKI67、CCNB1、TOP2A)
 - 下调: 1,847 个 (如 SFTPC、AGER)

功能富集:

- 上调基因富集于:
 - 细胞周期 ($p < 10^{-20}$)
 - DNA 复制
 - 有丝分裂
- 下调基因富集于:
 - 肺泡表面活性物质代谢
 - 气体交换

分子分型：

- 识别出 3 个分子亚型
 - 亚型 1：增殖型（高 MKI67）
 - 亚型 2：免疫型（高 PD-L1）
 - 亚型 3：代谢型（代谢通路激活）

(5) 临床意义 (0.5 分)

- 为精准医疗提供分子标志物
- 指导靶向药物选择
- 预测治疗响应和预后

实例 2：药物作用机制研究（简化版，作为备选）

设计：癌细胞 + 化疗药物处理 0h/6h/24h

结果：识别早期应答基因（6h 上调）和晚期凋亡基因（24h 上调）

应用：揭示药物作用的分子通路

【题 8】基因表达分析原理+图表（10 分）

原理部分同题 7，图表解读参考 Part 2 的火山图/热图解读模板

【题 9】蛋白质功能+疾病+AlphaFold（12 分）

标准答案框架：

一、蛋白质发挥作用的途径或机制（4 分）

1. 酶促催化（1 分）

- 机制：降低化学反应活化能，催化代谢反应
- 例子：苯丙氨酸羟化酶缺陷 → 苯丙酮尿症（PKU）
- 疾病：代谢酶缺陷导致底物累积或产物缺乏

2. 信号转导（1 分）

- 机制：传递细胞内外信号，调控细胞行为
- 例子：Ras 蛋白突变 → 持续激活 → 癌症
- 疾病：信号通路异常激活或抑制

3. 结构支撑（0.5 分）

- 机制：维持细胞和组织的机械强度
- 例子：胶原蛋白突变 → 成骨不全症
- 疾病：结构蛋白缺陷导致组织脆弱

4. 转运功能（0.5 分）

- 机制：跨膜或细胞内物质运输
- 例子：CFTR 蛋白缺陷 → 囊性纤维化
- 疾病：离子通道或转运体异常

5. 免疫识别（0.5 分）

- 机制：抗原识别和免疫应答
- 例子：抗体识别病原体
- 疾病：自身抗体攻击自身组织 → 自身免疫病

6. 蛋白质相互作用（0.5 分）

- 机制：形成多蛋白复合物执行功能
- 例子：核糖体装配、DNA 修复复合物
- 疾病：互作网络失调导致功能障碍

二、蛋白质与疾病相关的研究内容（4分）

（1）突变与疾病关联（1分）

- 致病突变识别（OMIM 数据库）
- 突变对蛋白结构/功能的影响预测
- 例：TP53 突变与多种癌症

（2）表达异常与疾病（1分）

- 蛋白质表达量变化（蛋白质组学）
- 肿瘤标志物开发（如 PSA、CEA）
- 例：HER2 过表达与乳腺癌

（3）翻译后修饰异常（0.5分）

- 磷酸化、糖基化、乙酰化异常
- 例：tau 蛋白过度磷酸化与阿尔茨海默病

（4）蛋白质聚集（0.5分）

- 错误折叠和聚集
- 例： β -淀粉样蛋白聚集 → 阿尔茨海默病
- 例： α -突触核蛋白聚集 → 帕金森病

（5）药物靶点研究（1分）

- 靶点蛋白筛选
- 药物-蛋白相互作用
- 例：EGFR 抑制剂治疗肺癌

三、AlphaFold 对蛋白质研究的影响（4分）

（1）革命性突破（1分）

AlphaFold2 于 2021 年实现了原子级精度的蛋白质结构预测，准确度接近实验测定（X 射线晶体学或冷冻电镜）。

（2）主要影响（2.5分）

1. 结构生物学民主化（1分）

- 降低门槛：无需昂贵的实验设备，几分钟预测结构
- 覆盖度暴增：AlphaFold Database 已预测 2 亿+蛋白结构
 - 覆盖 UniProt 中几乎所有已知蛋白
- 孤儿蛋白解析：无法结晶或表达的蛋白也能获得结构

2. 加速功能注释（0.75分）

- 通过结构推测功能（结构保守性高于序列）
- 识别活性位点和配体结合口袋
- 预测蛋白质相互作用界面

3. 推动药物设计（0.75分）

- 为药物靶点提供高质量结构模型
- **基于结构的药物设计（SBDD）**成为标准流程
- 加速先导化合物优化
- 抗体工程和蛋白质工程应用

（3）局限性与挑战（0.5分）

- 对多结构域、柔性区域预测仍有挑战
 - 无法预测动态构象变化
 - 配体结合和蛋白质-蛋白相互作用预测精度待提升
 - 仍需实验验证预测结果
-

【题 10】系统发生分析+图表（12 分）

标准答案框架：

一、什么是系统发生分析（2 分）

定义： 系统发生分析（Phylogenetic Analysis）是通过分析生物分子序列（DNA、RNA、蛋白质）的相似性和差异性，推断物种或基因间的进化关系，构建系统发生树（进化树，Phylogenetic Tree）的过程。

核心思想： 序列相似度反映进化距离——序列越相似，进化关系越近，分化时间越短。

二、系统发生分析的应用（3 分）

1. 物种分类与鉴定（0.5 分）

- 构建生命之树
- 新物种的分类定位
- 微生物物种鉴定（16S rRNA）

2. 进化关系研究（0.5 分）

- 物种起源和分化时间推断
- 研究进化速率
- 识别保守和快速进化区域

3. 基因家族分析（0.5 分）

- 追踪基因复制事件
- 区分直系同源（Ortholog）和旁系同源（Paralog）
- 研究基因功能分化

4. 病原体溯源（0.5 分）

- 追踪传染病起源和传播路径
- 例：COVID-19 病毒溯源
- 例：流感病毒进化监测

5. 保护生物学（0.5 分）

- 评估物种多样性
- 识别进化显著单元（ESU）
- 指导保护策略


6. 疫苗和药物设计（0.5 分）

- 识别保守靶点区域
- 预测病原体进化趋势

三、图表解读（7 分）

（1）基本结构识别（2 分）

典型进化树结构：



|—————|

0.05 替换/位点

要素识别：

- 分支 (Branch)：进化路径
- 节点 (Node)：共同祖先
- 末端节点：现存物种/序列
- 内部节点：假设的祖先
- 根 (Root)：共同祖先，由外群确定
- 枝长 (Branch Length)：进化距离
- 支持度：Bootstrap 值或后验概率

(2) 拓扑关系解读 (2 分)

姐妹群 (Sister Group)：

- 共享最近共同祖先的两个分支
- 例：人类与黑猩猩是姐妹群

单系群 (Monophyletic)：

- 包含共同祖先及其所有后代
- 例：所有灵长类

进化关系判断：

- 看节点位置，不看分支上下顺序
- 追溯到共同祖先经过的节点越少，关系越近

(3) 支持度分析 (1 分)

Bootstrap 值 (0-100)：

- 90：高度可靠
- 70-90：可靠
- <50：不可靠，需谨慎解释

贝叶斯后验概率 (0-1)：

- 0.95：高度支持
- 0.85-0.95：较好支持
- <0.85：支持度低

(4) 枝长与进化距离 (1 分)

标尺解读：

- "0.05 替换/位点"表示每 100 个核苷酸有 5 个替换
- 枝长越长，进化距离越远/进化速率越快
- 可用于估算分化时间（需要分子钟假设）

(5) 生物学结论 (1 分)

根据具体图表得出：

- 物种间的亲缘关系
- 分化时间估计
- 进化速率差异
- 保守性和特异性分析

图表解读示例答案：

"该系统发生树展示了灵长类的进化关系。拓扑结构显示，人类 (*Homo sapiens*) 与黑猩猩 (*Pan troglodytes*) 为姐妹群，关系最近，其节点 Bootstrap 值为 98，高度可靠。两者约在 600-700 万年前分化。人-黑猩猩支与大猩猩-猩猩支形成更大的类人猿单系群，支持度

为 85, 较为可靠。长臂猿最早从类人猿分化出去。外群定义了树根, 提供了进化方向。枝长标尺显示 0.05 替换/位点, 反映了各支系的进化速率。该树支持人类在灵长类中的系统位置, 验证了人科的单系性。”

PART 2: 论述题标准模板 (30 分)

【论述题】精准医疗研究设计 (30 分)

万能四段式模板 (600-650 字):

一、研究背景与选题意义 (6-8 分)

[根据题目给的精准医疗背景材料改写]

模板框架:

[疾病名]是[全球/中国]重大健康问题, 发病率/死亡率高, 但[现有问题: 如诊断滞后、治疗响应差异大、预后难预测]。传统的“一刀切”治疗模式效果有限, 患者迫切需要个体化精准医疗方案。

本研究拟利用多组学生物信息学方法, 系统分析[疾病/表型]的分子特征, 识别关键[差异基因/突变/通路/生物标志物], 构建[预后预测模型/分型系统/治疗响应预测模型]。

研究意义:

- (1) 科学意义: 揭示[疾病]分子机制, 填补[某领域]空白
- (2) 临床意义: 为精准诊疗提供分子依据, 改善患者预后
- (3) 社会意义: 降低医疗成本, 提高公共卫生水平

二、生物信息学分析方法 (核心, 15-18 分)

(一) 数据收集与预处理 (3-4 分)

1. 公共数据库数据获取:

- TCGA 数据库: [癌症类型]患者转录组数据 (约 XXX 例)
- GEO 数据库: [GSE 编号]芯片表达数据
- UK Biobank: 大队列验证数据 (50 万人群)
- 临床信息: 年龄、性别、分期、预后、治疗响应等

2. 数据预处理:

- 质量控制: 剔除低质量样本
- 批次效应校正: Combat/SVA
- 数据标准化: log2 转换、quantile normalization

(二) 多组学数据分析 (10-12 分) ★重点!

Step 1: 转录组学分析 (3-4 分)

1. 差异表达分析:

- 工具: DESeq2 (RNA-seq) / limma (芯片数据)
- 比较: [病例组 vs 对照组] 或 [亚组间比较]
- 筛选标准: $|\log_2FC| \geq 1$, $FDR < 0.05$
- 预期: 识别 XXX-XXX 个差异表达基因 (DEG)

2. 功能富集分析:

- GO 富集: 识别显著富集的生物学过程

- KEGG 通路：找出关键信号通路
- 工具：clusterProfiler、DAVID
- 预期：发现[免疫/代谢/增殖]相关通路异常

3. 共表达网络分析（可选）：

- WGCNA 识别共表达模块
- 关联临床表型
- 识别 Hub 基因

Step 2: 基因组学分析（如适用，2-3 分）

1. 突变分析：

- 体细胞突变识别（MuTect2/VarScan）
- 驱动突变筛选（OncodriveCLUST）
- 突变 signature 分析

2. 拷贝数变异（CNV）分析：

- GISTIC 识别显著扩增/缺失区域
- 关联基因表达变化

Step 3: 机器学习建模（4-5 分） ★ 必须包含！

1. 特征选择：

- 单因素 Cox 回归筛选预后相关基因 ($p < 0.05$)
- LASSO 回归特征降维，选择最优基因组合
- 避免过拟合

2. 模型构建：

方法选择：

- 分类问题：随机森林、SVM、XGBoost
- 生存分析：Cox 比例风险模型
- 深度学习：神经网络（如适用）

具体流程（以预后模型为例）：

a) 计算风险评分（Risk Score）：

$$\text{Risk Score} = \beta_1 \times \text{Gene}_1 + \beta_2 \times \text{Gene}_2 + \dots + \beta_n \times \text{Gene}_n$$

（ β 为 LASSO 回归系数）

b) 患者分层：

根据 Risk Score 中位数分为高风险组和低风险组

c) 生存分析：

- Kaplan-Meier 生存曲线
- Log-rank 检验比较组间差异
- ROC 曲线评估预测准确性（期望 AUC > 0.75）

3. 模型验证：

- 训练集：70%数据

- 测试集：30%数据
- 外部验证：UK Biobank 或 GEO 独立队列
- 评价指标：AUC、C-index、准确率、灵敏度、特异度

4. 临床变量整合（可选）：

- 结合年龄、性别、分期等临床变量
- 构建联合预测模型（Nomogram）
- 提高临床实用性

Step 4: 多组学整合（如适用，1-2 分）

- iCluster 整合聚类
- SNF（Similarity Network Fusion）
- 识别多组学驱动分子亚型

（三）关键技术路线总结（1 分）

数据收集 → 质控预处理 → 差异分析 → 功能富集 →
机器学习建模 → 外部验证 → 临床应用

三、实验验证与生信结合（5-6 分）

1. 候选基因筛选（1 分）：

从生信分析中选择：

- 差异倍数最大的基因（Top 10）
- 预后模型核心基因（Risk Score 权重高）
- 文献支持的已知靶点

2. 实验验证策略（3-4 分）：

（1）表达水平验证：

- qRT-PCR 验证 mRNA 水平（30-50 例临床样本）
- Western blot 验证蛋白水平
- 免疫组化（IHC）评估组织定位和表达

（2）功能验证：

- 细胞系实验：
 - * siRNA/shRNA 敲低候选基因
 - * 过表达载体构建
 - * 观察细胞增殖、迁移、侵袭、凋亡变化
- 动物模型（如条件允许）：
 - * 皮下移植瘤模型
 - * 评估肿瘤生长、转移
 - * 药物敏感性测试

（3）机制验证：

- 下游通路检测（Western blot）
- 蛋白质相互作用验证（Co-IP）
- 染色质免疫共沉淀（ChIP，如为转录因子）

3. 临床转化 (1 分):

- 回顾性临床队列验证 (100-200 例)
- 评估生物标志物的临床检测性能
- 前瞻性临床试验设计

四、预期结果与临床价值 (3-4 分)

1. 预期科学发现 (1.5 分):

- 识别 XXX-XXX 个[疾病]关键差异基因
- 发现[X]个显著富集的信号通路 (如 XX 通路、XX 通路)
- 构建包含[X]个基因的预后预测模型 (期望 AUC>0.75)
- 识别[2-4]个分子亚型, 各具特征性分子特征

2. 临床应用价值 (1.5 分):

- 精准诊断: 基于分子分型的诊断标准
- 预后评估: Risk Score 指导患者风险分层
- 治疗指导: 根据分子特征选择靶向药物
- 疗效监测: 动态监测生物标志物水平

3. 社会效益 (可选, 0.5 分):

- 降低无效治疗, 节约医疗资源
- 提高患者生存质量
- 减轻家庭和社会经济负担

 PART 3: 附加题模板 (10 分, 5 分钟速写)

【附加题】学习收获与建议 (10 分)

万能模板 (400 字):

一、学习收获与进步 (6 分)

通过本学期生物信息学课程的学习, 我在以下方面取得了显著进步:

1. 知识体系构建 (2 分):

- 系统掌握了生物信息学核心概念, 包括序列分析、数据库应用、基因表达分析、功能注释等
- 理解了从基因组到表型的多组学数据整合思路
- 认识到生物信息学在精准医学中的关键作用

2. 工具与方法运用 (2 分):

- 学会使用 BLAST 进行序列比对和功能注释
- 掌握了 RNA-seq 差异表达分析的基本流程
- 了解了 GO/KEGG 富集分析、系统发生分析等常用方法
- 初步具备利用公共数据库 (NCBI、KEGG、GO) 进行数据挖掘的能力

3. 科研思维培养 (1 分):

- 学会了如何设计生物信息学研究方案
- 理解了"湿实验"与"干实验"结合的重要性

- 培养了批判性思维和文献阅读能力

4. 自主学习能力 (1 分):

- 通过课后练习和文献阅读, 提高了自主学习能力
- 学会查阅在线资源 (数据库文档、教程、论坛)
- 克服了对编程和数据分析的畏惧心理

二、对课程的建议 (2 分)

1. 增加实践环节:

建议增加上机实操时间, 让学生亲手运行完整的分析流程 (如从 FASTQ 到差异基因列表), 加深理解

2. 案例教学:

多引入最新研究案例 (如 Nature/Science 论文), 展示生信在实际科研中的应用, 激发学习兴趣

3. 分层教学:

考虑不同专业背景学生的需求, 提供基础和进阶两个层次, 让有编程基础的同学也能有所收获

4. 工具培训:

系统讲解常用生信工具的安装和使用, 提供更多的在线资源链接和学习路径

三、文献自主学习建议 (1 分)

- 建议每周精读 1 篇高质量生信文章, 关注 Methods 和 Results 部分
- 善用 PubMed、Google Scholar 建立自己的文献库
- 学习 R/Python 编程语言, 能够复现论文中的图表
- 参加生信领域的在线研讨会和培训课程

四、感谢与展望 (1 分)

感谢老师们的悉心教导和耐心答疑, 让我认识到生物信息学在现代医学研究中的巨大潜力。这门课程为我未来的科研道路打下了坚实的基础。我希望能够将所学知识应用到临床研究中, 为推动精准医疗贡献自己的力量。